blatt06_nitschke_grisard

November 29, 2018

1 Aufgabe 15

a) Da beim *kNN*-Algorithmus muss die (euklidische) Norm zwischen den Test und Traningsdatenpunkten berechnet werden. Weichen die GröSSenordnungen der Attribute stark voneinander ab, kann es z.B. zu Rundungsfehlern kommen. Zudem ist der Abstandsbegriff sinnvoller, wenn die einzelnen Skalen normiert werden, da dann relative Abstände für alle Attribute gleich gewichtet werden.

b) Der Algorithmus wird als *lazy learner* bezeichnet, da er eigentlich gar nicht lernt. Der Trainingsdatensatz wird einfach nur abgespeichert und für jeden neuen Testdatensatz die k nächsten Nachbarn neu berechnet werden. Die Laufzeit der Lernphase ist verschwindend klein, während die Anwendungsphase lang dauert. Bei der *SVM* ist es genau andersherum.

c)

```
In [1]: import numpy as np
        import pandas as pd
        from pandas import DataFrame, Series
        from collections import Counter
        import matplotlib.pyplot as plt
        from ml import plots
        %matplotlib inline
        from graphviz import Source
        from matplotlib.colors import ListedColormap
```

Die Klassenstruktur:

```
In [2]: class KNN:
            def __init__(self, k):
                self.k = k

            def fit(self, X, y):
                self.training_data = X
                self.training_labels = y

            def predict(self, X):
                #calculate the eucleadian distance (ignore the root,
                #cause its a monoton function)
                #between each test event and each training event
```

```
        distance = (-2 * np.dot(X, self.training_data.T)
                    + np.sum(X**2, axis=1)[:, np.newaxis]
                    + np.sum(self.training_data**2, axis=1)[np.newaxis, :])

        #generate matrix with labels of the k nearest neighbours
        labels = self.training_labels.values[(np.argsort(distance))[:, :self.k]]

        #most common label of the k nearest neighbours as
        #prediction for each test event
        prediction = []
        for i in range(np.shape(labels)[0]):
            count = Counter(labels[i, :])
            prediction.append(count.most_common(1)[0][0])

        return prediction
```

d) Bringe zunächst die Daten in die benötigte Form:

```
In [3]: #read hdf5 file
        neutrino_signal = pd.read_hdf('NeutrinoMC.hdf5', key = 'Signal')

        #select the accepted events
        neutrino_signal = neutrino_signal[neutrino_signal.AcceptanceMask]

        #delete the energy and the acceptancemask (not relevant for this task)
        neutrino_signal = neutrino_signal.drop(columns = ['Energy', 'AcceptanceMask'])

        #reset the index of the DataFrame
        neutrino_signal = neutrino_signal.reset_index(drop = True)

        #add label to the signal events
        neutrino_signal['label'] = Series(data = ['signal' for i in neutrino_signal.x])
```

Das gleiche für die Untergrundevents:

```
In [4]: neutrino_background = pd.read_hdf('NeutrinoMC.hdf5', key = 'Background')
        neutrino_background['label'] = Series(data = ['background' for i in
                                                      neutrino_background.x])
```

Eine Funktion um einen gewünschten gemischten Datensatz aus Signal und Untergrund zu erstellen:

```
In [5]: def mix_sample(signal_events, background_events, n_signal, n_background):
            data_set = pd.concat([background_events.sample(n_background),
                                  signal_events.sample(n_signal)],
                                 ignore_index=True)
            X = data_set.drop(columns = 'label')
            y = data_set['label']
            return X, y
```

Funktionen für Reinheit usw:

```
In [6]: #Reinheit
        def precision(true_pos, false_pos):
            return len(true_pos) / (len(true_pos) + len(false_pos))

        #Effizienz
        def recall(true_pos, false_neg):
            return len(true_pos) / (len(true_pos) + len(false_neg))

        #Signifikanz
        def significance(true_pos, false_pos):
            return len(true_pos) / np.sqrt(len(true_pos) + len(false_pos))
```

Generiere den Trainings- und Testdatensatz:

```
In [7]: X_training, y_training = mix_sample(neutrino_signal, neutrino_background, 5000, 5000)
        X_test, y_test = mix_sample(neutrino_signal, neutrino_background, 10000, 20000)
```

Ab hier ist das Vorgehen für die Aufgabenteile d)-f) analog, wesegen eine Funktion für die Prozedur geschrieben wird:

```
In [8]: def procedure(k, X_training, y_training, X_test, y_test):
            #use the knn algorithm
            knn = KNN(k = k)
            knn.fit(X = X_training, y = y_training)
            prediction = knn.predict(X = X_test)

            #add results to test data set
            X_test['prediction'] = Series(prediction)
            X_test['truth'] = y_test


            #calculate true positive etc
            true_positive  = X_test[(X_test.truth == 'signal') &
                                    (X_test.prediction == 'signal')]

            true_negative  = X_test[(X_test.truth == 'background') &
                                    (X_test.prediction == 'background')]

            false_positive = X_test[(X_test.truth == 'background') &
                                    (X_test.prediction == 'signal')]

            false_negative = X_test[(X_test.truth == 'signal') &
                                    (X_test.prediction == 'background')]

            #calculate precision etc
            precision_knn = precision(true_positive, false_positive)
            recall_knn = recall(true_positive, false_negative)
```

```
        significance_knn = significance(true_positive, false_positive)

        print(f'Reinheit: \t{precision_knn}\nEffizienz: \t{recall_knn}\nSignifikanz: \t{sig
```

Hier nun KNN Algorithmus mit $k = 10$:

```
In [9]: procedure(10, X_training, y_training, X_test, y_test)
```

```
Reinheit:         0.8294626788927929
Effizienz:         0.9679
Signifikanz:         89.60116778816749
```

e) Nun $log_{10}(N)$ statt N:

```
In [10]: neutrino_signal_e = neutrino_signal
         neutrino_signal_e['log10NumberOfHits'] = np.log10(neutrino_signal['NumberOfHits'])
         neutrino_signal_e = neutrino_signal_e.drop(columns = 'NumberOfHits')

         neutrino_background_e = neutrino_background
         neutrino_background_e['log10NumberOfHits'] = np.log10(neutrino_background['NumberOfHit
         neutrino_background_e = neutrino_background_e.drop(columns = 'NumberOfHits')
```

Nun das gleiche wie oben:

```
In [11]: X_training, y_training = mix_sample(neutrino_signal_e,
                                              neutrino_background_e,
                                              5000, 5000)
         X_test, y_test = mix_sample(neutrino_signal_e,
                                     neutrino_background_e,
                                     10000, 20000)
```

```
In [12]: procedure(10, X_training, y_training, X_test, y_test)
```

```
Reinheit:         0.8692259952123416
Effizienz:         0.9804
Signifikanz:         92.31409240772395
```

Kommentar: Alle Attribute werden besser. Wie oben erwähnt ist dies durch eine Umskalierung des Attributs 'Hits' bedingt.

f) Nun das ganze mit $k = 20$:

```
In [13]: X_training, y_training = mix_sample(neutrino_signal, neutrino_background, 5000, 5000)
         X_test, y_test = mix_sample(neutrino_signal, neutrino_background, 10000, 20000)
```

```
In [14]: procedure(20, X_training, y_training, X_test, y_test)
```

```
Reinheit:         0.8204801900398745
Effizienz:         0.9671
Signifikanz:         89.07785312789944
```

Kommentar: Alle Attribute werden schlechter.

2 Aufgabe 16

Der handschriftliche Teil der Aufgabe befindet sich am Ende der pdf.

```
In [15]: X = DataFrame()
         X['temperature'] = Series([29.4, 26.7, 28.3, 21.1, 20, 18.3, 17.8, 22.2, 20.6, 23.9, 1
         X['report'] = Series([2, 2, 1, 0, 0, 0, 1, 2, 2, 0, 2, 1, 1, 0])
         X['humidity'] = Series([85, 90, 78, 96, 80, 70, 65, 95, 70, 80, 70, 90, 75, 80])
         X['wind'] = Series([False, True, False, False, False, True, True, False, False, False
         #X

         y = DataFrame({'football': Series([False, False, True, True, True, False, True, False
```

```
In [16]: def entropy(y, splits = [[True for y in range(len(y))]]):
             H = []
             for split in splits:
                 entropy = 0
                 values = Counter(y[split]).most_common()
                 for value in values:
                     entropy -= value[1] / len(y[split]) * np.log2(value[1] / len(y[split]))
                 H.append(entropy)
             return np.array(H)

         def information_gain(y, splits):
             return entropy(y) - entropy(y, splits)
```

```
In [17]: print(entropy(y.football))
```

```
[0.94028596]
```

```
In [18]: report_split = [1, 2, 3]
         report_splits = [X.report <= report for report in report_split]

         report_information_gain = information_gain(y.football, report_splits)
         plt.plot(report_split, report_information_gain, 'ro')
         plt.xticks([1, 2, 3])
         plt.xlabel('Schnitt Wetterbericht')
         plt.ylabel('Informationsgewinn')
         None
```

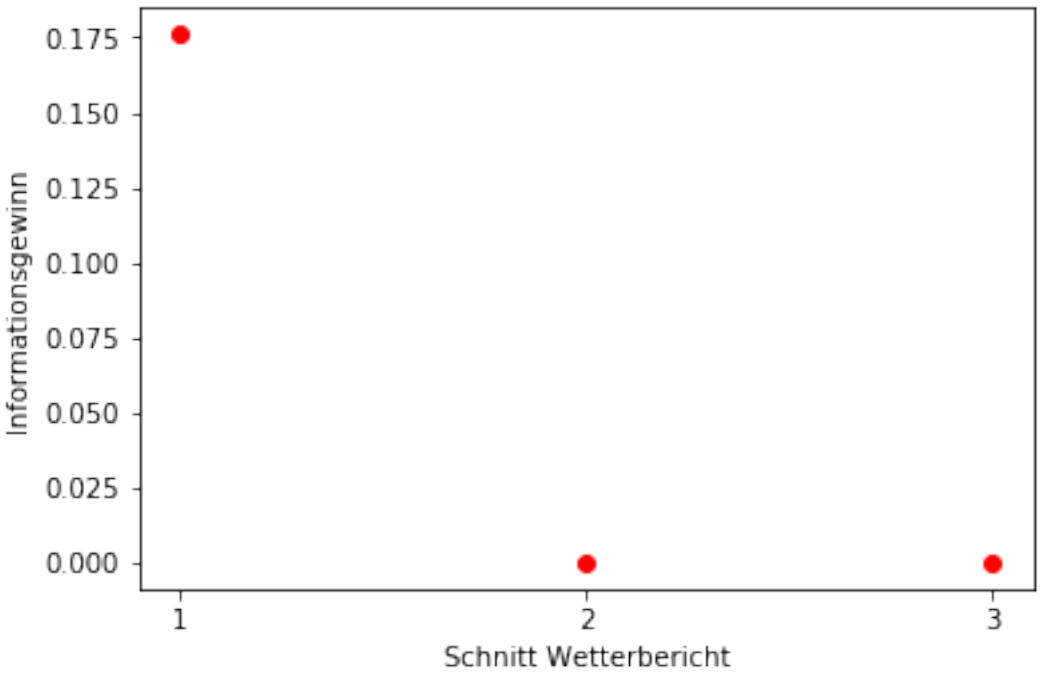


```
In [19]: humidity_split = np.linspace(min(X.humidity), max(X.humidity), 200)
         humidity_splits = [X.humidity <= H for H in humidity_split]

         H_information_gain = information_gain(y.football, humidity_splits)
         plt.plot(humidity_split, H_information_gain, 'r-')
         plt.xlabel('Schnitt-Luftfeuchtigkeit')
         plt.ylabel('Informationsgewinn')
         None
```

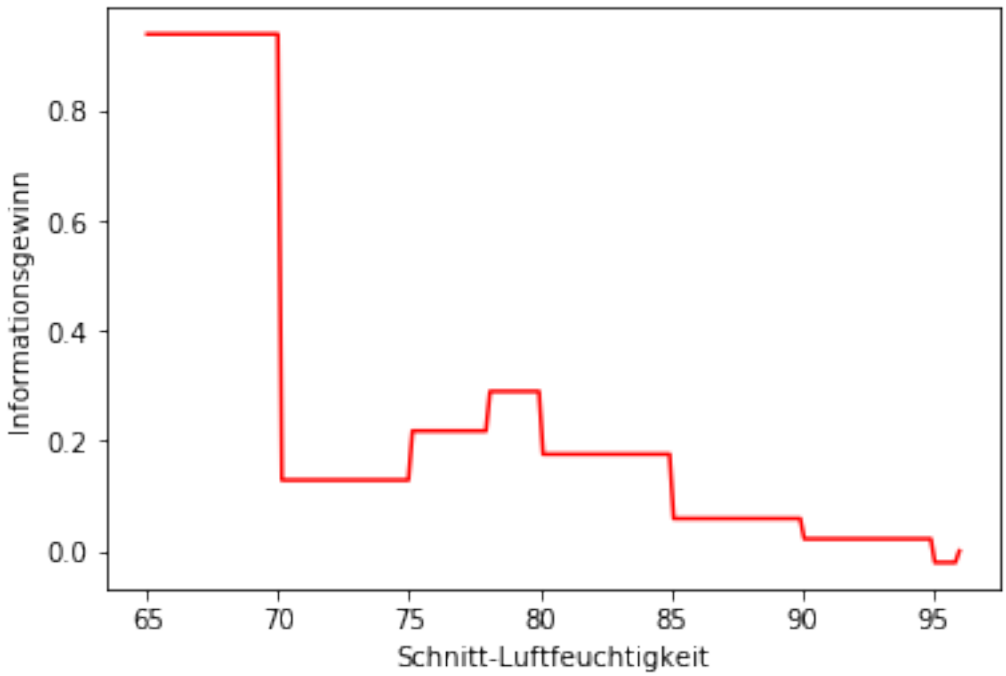


```
In [20]: temperature_split = np.linspace(min(X.temperature), max(X.temperature), 200)
         temperature_splits = [X.temperature <= T for T in temperature_split]


         T_information_gain = information_gain(y.football, temperature_splits)
         plt.plot(temperature_split, T_information_gain, 'r-')
         plt.xlabel('Schnitt-Temperatur')
         plt.ylabel('Informationsgewinn')
         None
```

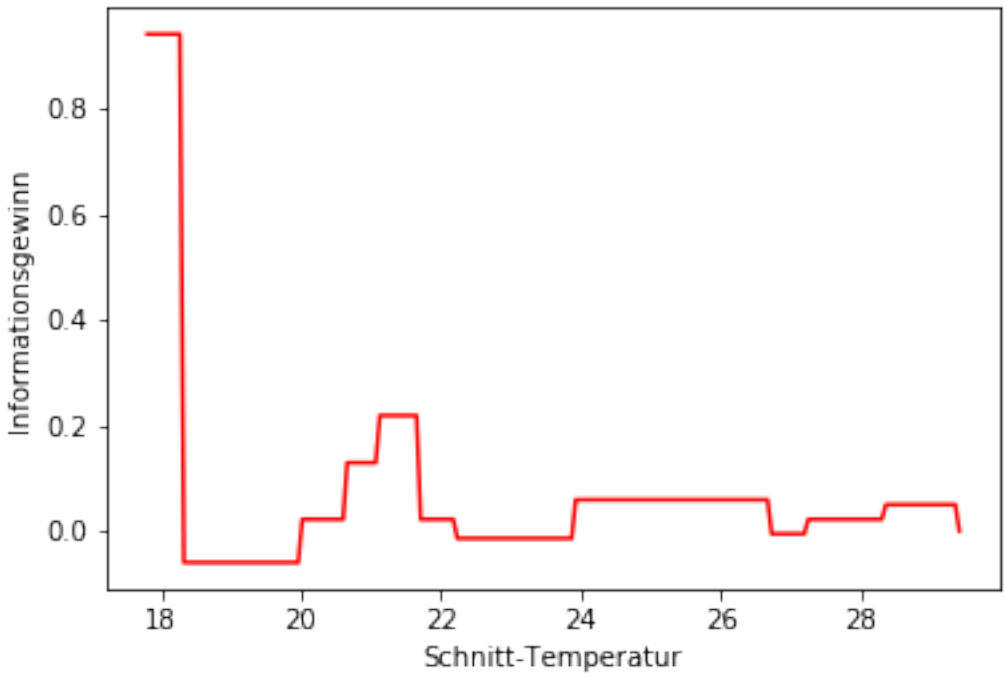

Das Attribut Temperatur eignet sich am besten.

```
In [21]: from sklearn.tree import DecisionTreeClassifier
         from sklearn import tree

         discrete_cmap = ListedColormap(['xkcd:red', 'xkcd:blue'])
         clf = DecisionTreeClassifier(max_depth=10, criterion='entropy')
         clf.fit(X, y)
         tree.export_graphviz(clf, out_file = 'tree.dot')
```

3 Aufgabe 17

Wie sollten nicht-numerische Datentypen wie beispielsweise Strings vor der Analyse behandelt werden müssen? b) Kann es hilfreich sein Attribute zu normieren? Wenn ja, wieso? c) Wie kann mit Lücken in den Daten oder NaNs und Infs verfahren werden? d) Was ist beim Zusammenführen von Datensätzen zu beachten? e) Welche Attribute sollten vor dem Trainieren des Klassifizierers aus dem Datensatz entfernt werden. Wie kann dabei eine Reduktion redundanter Informationen er- reicht werden? Was mum ss speziell bei simulationsbasierten Methoden berücksichtigt werden?

a) Aus den Strings sollten vergleichbare Attribute generiert werden, z.B. die Länge oder die Anzahl an bestimmten Buchstaben. Falls die Strings nur eine Eigenschaft angeben, kann diese einer Zahl zugeordnet werden.

b) Dies kann z.B. für den kNN Algorithmus relevant sein, wie oben bereits erklärt.

c) Man kann diese Attribute oder den jeweiligen Datenpunkt einfach weglassen. Oder interpretieren, was z.B. Infs in dem Kontext bedeuten und dann entsprechend einen anderen Wert

zuweisen.

d) Die Datensätze müssen über die selben Attribute verfügen.

e) Attribute, die für alle Daten gleich sind enthalten z.B. keinerlei Information. Manche Daten stehen vielleicht in einem funktionellen Zusammenhang zueinander. Einer Reduktion der Attribute kann z.B. mit der PCA erreicht werden.

SMD BGH 6

A16

a) H(S): Fußball ins. 14 Tage → 9 gespielt
→ 5 nicht

$$H(S) = -\frac{9}{14}\log_2\left(\frac{9}{14}\right) - \frac{5}{14}\log_2\left(\frac{5}{14}\right) \approx 0.940286$$

b) Wind = schwach: 8× → 6 gespielt
→ 2 nicht

$$H(W_{schw}) = -\frac{6}{8}\log_2\left(\frac{6}{8}\right) - \frac{2}{8}\log_2\left(\frac{2}{8}\right) = 0.8112781$$

Wind = stark: 6× → 3 gespielt
→ 3 nicht

$$H(W_{stark}) = -\frac{1}{2}\log_2\left(\frac{1}{2}\right) - \frac{1}{2}\log_2\left(\frac{1}{2}\right) = 1$$

$$Gain(W_{schw}) = 0.940286 - 0.811278 = 0,129008$$

$$Gain(W_{stark} = 0,940286 - 1 = -0,059714$$

Gesamt: $Gain(Wind) = H(S) - \frac{8}{14}H(W_{schw}) - \frac{6}{14}H(W_{stark})$

$$= 0.048127$$

c) / d): siehe ipynb

A18

a) $$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{P(B \cap A)}{P(B)} = \frac{P(B|A)\,P(A)}{P(B)}$$

b) $P(W|F) = P(W_1|F)\,P(W_2|F)\,P(W_3|F)\,P(W_4|F)$

$P(W) = P(W_1)\,P(W_2)\,P(W_3)\,P(W_4)$ da W_i unabhängig

gesucht $P(ja|$ stark, hoch, kalt, sonnig$)$

$P(stark|ja) = 1/3$ $P(hoch|ja) = 1/3$ $P(kalt|ja) = 1/3$

$P(sonnig|ja) = 2/9$ $P(ja) = 9/14$

$P(stark) = 3/7$ $P(hoch) = 1/2$ $P(kalt) = 3/7$

$P(sonnig) = 3/14$

$\Rightarrow P(F|W) = \frac{P(W|F) \cdot P(F)}{P(W)}$

$P(W|F) = \frac{1}{3} \cdot \frac{1}{3} \cdot \frac{1}{3} \cdot \frac{2}{9} = \frac{2}{243}$ $\quad P(F) = 9/14$

$P(W) = 3/7 \cdot 1/2 \cdot 3/7 \cdot \frac{3}{14} = \frac{27}{1372}$

$\Rightarrow P(F|W) = \frac{196}{729} \approx 0{,}27$

$\Rightarrow$ Die Wahrscheinlichkeit, dass Fußball gespielt wird beträgt 27 %

c) $P(\text{Biß} | \text{ja}) = 0$

→ Wahrscheinlichkeit wäre direkt null

→ Berechne stattdessen ~~$P(\text{Biß}|\text{nein})$~~ $P(\text{nein} | W_{\text{mager}})$

$P(W_{\text{mager}} | \text{nein}) = 2/5 \cdot 4/5 \cdot 1/5 \cdot 1/5 = \frac{8}{625}$

$P(W_{\text{mager}}) = 4/7 \cdot 1/2 \cdot 1/14 \cdot 3/14 = \frac{3}{686}$

$P(\text{nein}) = 5/14$

$P(\text{nein} | W_{\text{mager}}) = \frac{\frac{8}{625} \cdot \frac{5}{14}}{\frac{3}{686}} \approx 0{,}976$

$\Rightarrow P(\text{ja} | W_{\text{mager}}) = 1 - P(\text{nein} | W_{\text{mager}}) \approx 2{,}4\ \%$

andere Möglichkeit:

$P(\text{ja} | \text{schwach} \cap \text{hochsensig})$

$= \frac{2/3 \cdot 1/3 \cdot 2/9 \cdot 9/14}{4/7 \cdot 1/2 \cdot 3/14} = \frac{14}{27} \Rightarrow \approx 52\ \%$